



Univerzitet u Beogradu

Elektrotehnički fakultet

Katedra za Signale i sisteme

Vizuelna procena kvaliteta hoda MuJoCo politika iz RGB videa

Poređenje klasičnog motion baseline-a i R3D-18 transfer
učenja

Student:	Aleksa Mojsić
Broj indeksa:	25/3319
Predmet:	Kompjuterska Vizija

Beograd, avgust 2026.

Sadržaj

Sažetak	ii
1 Uvod	1
2 Teorijska osnova	2
3 Pregled implementacije	7
4 Definicija skora	8
5 Podaci i metodologija	9
6 Vizuelne osobine i motion representation	11
7 Eksperimenti i rezultati	12
8 Vizuelni prikazi iz sistema	14
9 Diskusija	16
10 Ograničenja i budući rad	17
11 Zaključak	18
Literatura	19

Sažetak

Ovaj rad razmatra vizuelnu procenu simulatorom izvedenog kvaliteta hoda humanoidnog agenta na osnovu spoljnog RGB videa. Klasični baseline kombinuje gust optički tok, body-centered poravnanje, PCA/SVD model kretanja i Ridge regresiju. Novi transfer baseline koristi zamrznuti R3D-18 model prethodno obučen na Kinetics-400, dve vremenski normalizovane video sekvence, PCA whitening naučen bez labela i malu Ridge regresionu glavu.

Reprezentacija se uči na 975 neoznačenih walking klipova: 580 CMU kinematičkih rendera i 395 realnih GaHu snimaka. Supervised skup sadrži 54 bočna MuJoCo klipa iz devet nezavisnih politika. Podela je grupisana po politici. Nested leave-one-policy-out evaluacija pojedinačnih klipova daje MAE 11.23, dok agregiranje šest scenarija u ocenu politike smanjuje MAE na 5.84 uz $R^2 = 0.830$ i Spearman korelaciju 0.983. Na fiksnom test skupu R3D-18 model postiže MAE 12.35, naspram 22.17 za train-mean baseline i 35.84 za klasični motion model. Rezultat predstavlja obećavajući istraživački baseline, ali ne i klinički validiran skor: labele su simulatorski proxy, a broj nezavisnih politika je i dalje mali.

Glava 1

Uvod

Procena kvaliteta pokreta iz video sekvence predstavlja klasičan problem na preseku računarskog vida, analize kretanja i procene kvaliteta akcije (Action Quality Assessment). U opštem slučaju, zadatak podrazumeva da se na osnovu same posmatrane sekvence proceni koliko je neko izvodjenje pokreta stabilno, pravilno, ritmično i uskladjeno sa očekivanim obrascem. Takav problem je naročito zanimljiv kada dodatne informacije nisu dostupne, odnosno kada sistem ne vidi ni kontakte, ni sile, ni unutrašnja stanja kontrolera, već isključivo video snimak.

U ovom projektu fokus nije na ljudskom hodu iz kliničkih baza podataka, već na humanoidnom agentu koji hoda u simulatoru i čiji se izlazi renderuju u RGB video formatu. Ta postavka je korisna iz dva razloga. Prvo, omogućava da se za svaki klip dobije izveden ciljni skor iz simulator telemetry signala. Drugo, uvodi stroga ograničenja u inferenciji: model za procenu kvaliteta hoda koristi isključivo video, bez direktnog pristupa internim podacima koji su korišćeni za formiranje target-a.

Polazna hipoteza rada glasi da se u vizuelnom obrascu hoda nalazi dovoljno informacije za aproksimaciju ukupnog simulator-proxy skora. Hipoteza se proverava poredjenjem dva pristupa. Klasična grana koristi pripremu frejmova, optički tok, poravnanje, PCA motion basis, temporalne osobine i regresiju. Transfer grana koristi prethodno obučenu spatiotemporalnu R3D-18 reprezentaciju, neoznačene walking klipove za PCA/whitening i malu regresionu glavu. Time klasični metod ostaje transparentan dijagnostički baseline, dok se direktno meri dobitak modernije video reprezentacije.

Važno je naglasiti da ovde cilj nije da se simulacioni skor predstavi kao medicinska istina. Naprotiv, skor je izvedena veličina konstruisana iz simulatorskih signala. Time se dobijaju dosledne labele za eksperiment, ali se istovremeno uvodi i osnovno ograničenje rada: kvalitet target-a direktno utiče na kvalitet modela. Zbog toga se rezultati u ovom radu tumače pre svega kao ocena funkcionalnosti pipeline-a i njegove sposobnosti da iz vizuelnog signala izvuče korisne indikatore kvaliteta hoda.

Glava 2

Teorijska osnova

Najveći deo teorijskog oslonca za ovaj projekat dolazi iz knjige Richarda Szeliskog *Computer Vision: Algorithms and Applications*. Iako rad ne implementira jedan gotov algoritam iz knjige u celini, gotovo svaka ključna faza sistema ima jaku vezu sa odgovarajućim poglavljem: filtriranje i preprocessing slike, procena kretanja, poravnanje, linearni podprostori i least-squares modeli.

Prva važna teorijska komponenta je gust optički tok. U kontekstu ovog projekta, optički tok predstavlja procenu lokalnih pomeraja između susednih frejmova video sekvence. Na taj način se dinamička informacija iz hoda pretvara u polje vektora koje direktnije opisuje kretanje tela nego same RGB vrednosti. Ovaj izbor je prirodan, jer je kvalitet hoda mnogo više povezan sa ritmom, stabilnošću i koordinacijom pokreta nego sa teksturom slike.

Druga komponenta je translaciono poravnanje. Ako kamera ili ceo agent imaju izraženo globalno kretanje kroz kadar, apsolutni optički tok može biti dominiran tom velikom translacijom, pa sitnije razlike između stabilnog i nestabilnog hoda postaju teže uočljive. Zbog toga se procenjuje body-centered residual flow, odnosno tok iz koga je uklonjeno dominantno globalno pomeranje. Takav signal je pogodniji za analizu obrasca samog hoda.

Treća komponenta je ideja naučenih modela kretanja. Umesto da se svako polje toka posmatra izolovano, više uzastopnih polja se slaže u visoku dimenziju, centriraju se i dekomponuju preko SVD/PCA. Rezultat su bazna polja kretanja i temporalni koeficijenti koji daju kompaktnu reprezentaciju sekvence. Ta reprezentacija je interpretabilnija i mnogo pogodnija za jednostavniji regresioni model od direktnog rada nad sirovim pikselima.

8.1 Translational alignment

The simplest way to establish an alignment between two images or image patches is to shift one image relative to the other. Given a *template* image $I_0(\mathbf{x})$ sampled at discrete pixel locations $\{\mathbf{x}_i = (x_i, y_i)\}$, we wish to find where it is located in image $I_1(\mathbf{x})$. A least squares solution to this problem is to find the minimum of the *sum of squared differences* (SSD) function

$$E_{\text{SSD}}(\mathbf{u}) = \sum_i [I_1(\mathbf{x}_i + \mathbf{u}) - I_0(\mathbf{x}_i)]^2 = \sum_i e_i^2, \quad (8.1)$$

where $\mathbf{u} = (u, v)$ is the *displacement* and $e_i = I_1(\mathbf{x}_i + \mathbf{u}) - I_0(\mathbf{x}_i)$ is called the *residual error* (or the *displaced frame difference* in the video coding literature).¹ (We ignore for the moment the possibility that parts of I_0 may lie outside the boundaries of I_1 or be otherwise not visible.) The assumption that corresponding pixel values remain the same in the two images is often called the *brightness constancy constraint*.²

In general, the displacement $\mathbf{u}$ can be fractional, so a suitable interpolation function must be applied to image $I_1(\mathbf{x})$. In practice, a bilinear interpolant is often used but bicubic interpolation can yield slightly better results (Szeliski and Scharstein 2004). Color images can be processed by summing differences across all three color channels, although it is also possible to first transform the images into a different color space or to only use the luminance (which is often done in video encoders).

Robust error metrics. We can make the above error metric more robust to outliers by replacing the squared error terms with a robust function $\rho(e_i)$ (Huber 1981; Hampel, Ronchetti, Rousseeuw *et al.* 1986; Black and Anandan 1996; Stewart 1999) to obtain

$$E_{\text{SRD}}(\mathbf{u}) = \sum_i \rho(I_1(\mathbf{x}_i + \mathbf{u}) - I_0(\mathbf{x}_i)) = \sum_i \rho(e_i). \quad (8.2)$$

The robust norm $\rho(e)$ is a function that grows less quickly than the quadratic penalty associated with least squares. One such function, sometimes used in motion estimation for video coding because of its speed, is the *sum of absolute differences* (SAD) metric³ or L_1 norm, i.e.,

$$E_{\text{SAD}}(\mathbf{u}) = \sum_i |I_1(\mathbf{x}_i + \mathbf{u}) - I_0(\mathbf{x}_i)| = \sum_i |e_i|. \quad (8.3)$$

¹ The usual justification for using least squares is that it is the optimal estimate with respect to Gaussian noise. See the discussion below on robust error metrics as well as Appendix B.3.

² Brightness constancy (Horn 1974) is the tendency for objects to maintain their perceived brightness under varying illumination conditions.

³ In video compression, e.g., the H.264 standard (<http://www.itu.int/rec/T-REC-H.264>), the sum of absolute transformed differences (SATD), which measures the differences in a frequency transform space, e.g., using a Hadamard transform, is often used since it more accurately predicts quality (Richardson 2003).

Slika 2.1: Strana iz Szeliski draft-a koja služi kao teorijska osnova za translaciono poravnanje i odvajanje globalnog i lokalnog kretanja (PDF strana 406).

Chellappa 1997; Srinivasan, Chellappa, Veeraraghavan *et al.* 2005). Algorithms for stabilization run inside both hardware devices, such as camcorders and still cameras, and software packages for improving the visual quality of shaky videos.

In their paper on full-frame video stabilization, Matsushita, Ofek, Ge *et al.* (2006) give a nice overview of the three major stages of stabilization, namely motion estimation, motion smoothing, and image warping. Motion estimation algorithms often use a similarity transform to handle camera translations, rotations, and zooming. The tricky part is getting these algorithms to lock onto the background motion, which is a result of the camera movement, without getting distracted by independent moving foreground objects. Motion smoothing algorithms recover the low-frequency (slowly varying) part of the motion and then estimate the high-frequency shake component that needs to be removed. Finally, image warping algorithms apply the high-frequency correction to render the original frames as if the camera had undergone only the smooth motion.

The resulting stabilization algorithms can greatly improve the appearance of shaky videos but they often still contain visual artifacts. For example, image warping can result in missing borders around the image, which must be cropped, filled using information from other frames, or hallucinated using inpainting techniques (Section 10.5.1). Furthermore, video frames captured during fast motion are often blurry. Their appearance can be improved either using deblurring techniques (Section 10.3) or stealing sharper pixels from other frames with less motion or better focus (Matsushita, Ofek, Ge *et al.* 2006). Exercise 8.3 has you implement and test some of these ideas.

In situations where the camera is translating a lot in 3D, e.g., when the videographer is walking, an even better approach is to compute a full structure from motion reconstruction of the camera motion and 3D scene. A smooth 3D camera path can then be computed and the original video re-rendered using view interpolation with the interpolated 3D point cloud serving as the proxy geometry while preserving salient features (Liu, Gleicher, Jin *et al.* 2009). If you have access to a camera array instead of a single video camera, you can do even better using a light field rendering approach (Section 13.3) (Smith, Zhang, Jin *et al.* 2009).

8.2.2 Learned motion models

An alternative to parameterizing the motion field with a geometric deformation such as an affine transform is to learn a set of basis functions tailored to a particular application (Black, Yacoob, Jepson *et al.* 1997). First, a set of dense motion fields (Section 8.4) is computed from a set of training videos. Next, singular value decomposition (SVD) is applied to the stack of motion fields $u_t(x)$ to compute the first few singular vectors $v_k(x)$. Finally, for a new test sequence, a novel flow field is computed using a coarse-to-fine algorithm that estimates the

Slika 2.2: Strana iz Szeliski draft-a na kojoj se oslanja ideja naučenih modela kretanja i PCA baznih vektora (PDF strana 425).




Figure 8.11 Octree spline-based image registration of two vertebral surface models (Szeliski and Lavallée 1996) © 1996 Springer: (a) after initial rigid alignment; (b) after elastic alignment; (c) a cross-section through the adapted octree spline deformation field.

matic mode but more accurate results can be obtained by locating a few key *landmarks*. More recent papers on deformable medical image registration, including performance evaluations, include (Klein, Staring, and Pluim 2007; Glocker, Komodakis, Tziritas *et al.* 2008).

As with other applications, regular volumetric splines can be enhanced using selective refinement. In the case of 3D volumetric image or surface registration, these are known as *octree splines* (Szeliski and Lavallée 1996) and have been used to register medical surface models such as vertebrae and faces from different patients (Figure 8.11).

8.4 Optical flow

The most general (and challenging) version of motion estimation is to compute an independent estimate of motion at *each* pixel, which is generally known as *optical* (or *optic*) *flow*. As we mentioned in the previous section, this generally involves minimizing the brightness or color difference between corresponding pixels summed over the image,

$$E_{\text{SSD-OF}}(\{\mathbf{u}_i\}) = \sum_i [I_1(\mathbf{x}_i + \mathbf{u}_i) - I_0(\mathbf{x}_i)]^2. \quad (8.69)$$

Since the number of variables $\{\mathbf{u}_i\}$ is twice the number of measurements, the problem is underconstrained. The two classic approaches to this problem are to perform the summation *locally* over overlapping regions (the *patch-based* or *window-based* approach) or to add smoothness terms on the $\{\mathbf{u}_i\}$ field using regularization or Markov random fields (Section 3.7) and to search for a global minimum.

The patch-based approach usually involves using a Taylor series expansion of the displaced image function (8.35) in order to obtain sub-pixel estimates (Lucas and Kanade 1981).

Slika 2.3: Strana iz Szeliski draft-a relevantna za gust optički tok i formulaciju problema procene pomeraja izmedju frejmova (PDF strana 431).

Pored procene toka, bitna je i vremenska struktura hoda. Stabilan hod je približno periodičan: koraci se smenjuju pravilnim ritmom, leva i desna strana imaju očekivanu simetriju, a promene brzine nisu nasilne i nasumične. Zato su u projektu korišćene temporalne osobine zasnovane na autokorelaciji, Furijeovim sažecima i promeni PCA koeficijenata kroz vreme. Na kraju, sve te osobine ulaze u jednostavan ali stabilan regresioni model koji predviđa ukupni skor i komponente kvaliteta hoda.

Transfer baseline dopunjuje ovu teorijsku osnovu trodimenzionalnim konvolucijama koje istovremeno obrađuju prostornu i vremensku osu video sekvence. Umesto

fine-tune-ovanja velikog modela na samo 54 označena klipa, R3D-18 backbone ostaje zamrznut. Takav transfer učenja koristi opšte motion osobine naučene na Kinetics-400 skupu, smanjuje broj trainable parametara i rizik od overfitting-a. PCA/whitening zatim prilagodjava embedding prostoru lokalnih walking videa bez upotrebe njihovih quality labela.

Glava 3

Pregled implementacije

Implementacija projekta je organizovana tako da prati prirodan tok obrade video podataka. Modul `src/gait_aqa/data/` zadužen je za pripremu manifesta, rad sa ulaznim video klipovima i organizaciju dataset-a. Modul `src/gait_aqa/vision/` predstavlja jezgro klasičnog computer vision pristupa: preprocessing frejmova, foreground obradu, procenu optičkog toka, poravnanje i izgradnju motion basis modela.

Posebni moduli sadrže klasični regresioni model, zamrznuti video-transfer pipeline, evaluaciju metrika i generisanje vizuelnih izlaza. Takva podela odvaja numeričku obradu od prezentacije rezultata i čini sistem lakšim za proveru.

U praktičnom smislu, projekat se koristi kroz jedinstveni `gait-aqa` CLI. Time se izbegavaju duplicirane wrapper skripte, a priprema podataka, trening, evaluacija i scoring ostaju jasno odvojene podkomande.

Tabela 3.1: Glavni delovi repozitorijuma i njihova uloga

Putanja	Uloga u sistemu
<code>MUJOCo_videos_better/</code>	Terminal-safe side i front-oblique MuJoCo renderi.
<code>CMU_reference_videos/</code>	BVH walking reference i MuJoCo renderi.
<code>datasets/gahu/</code>	Realni side-view walking klipovi bez quality labela.
<code>datasets/disabled_gait/</code>	Frontalni realni klipovi samo za OOD proveru.
<code>data/manifests/</code>	CSV manifesti i train/val/test podele.
<code>src/gait_aqa/vision/</code>	Preprocessing, optički tok, poravnanje i motion basis.
<code>src/gait_aqa/training/</code>	Klasični i R3D-18 transfer trening.
<code>output/</code>	Lokalni modeli, cache, predikcije i vizuelni izlazi.
<code>reports/</code>	PDF izveštaj, dokumentacija i LaTeX izvor.

Glava 4

Definicija skora

Ukupni skor je preuzet direktno iz walker export-a i preslikan iz opsega $[0, 1]$ u $[0, 100]$. Izvorni walker ga definiše kao scenario-relative težinski prosek stabilnosti, praćenja, uspravnosti i glatkoće:

$$\begin{aligned}\text{composite} &= 0.40 \cdot \text{stability} + 0.30 \cdot \text{tracking} \\ &+ 0.20 \cdot \text{upright} + 0.10 \cdot \text{smoothness}\end{aligned}$$

Kompaktni video manifest ne sadrži originalne normalizovane komponente niti `mean_action_rate_norm`, pa ih nije moguće korektno rekonstruisati. Ponovna min-max normalizacija na manjem lokalnom skupu promenila bi definiciju target-a. Zato se koristi samo direktno podržan ukupni skor, survival-derived stability i indikator pada.

Tabela 4.1: Komponente skora i njihovo tumačenje

Komponenta	Značenje
Overall	Sto puta izvorni <code>composite_score</code> .
Stability	Sto puta udeo sekvence pre prvog pada.
Fall	Reset, terminalni događaj ili survival manji od jedan.
Ostale komponente	Nedostupne u trenutnom export-u; ostaju prazne.

Model fituje samo ciljeve za koje postoje stvarne oznake. Nedostupne komponente i nepravilnosti ostaju prazne umesto da im se dodeli veštačka vrednost nula ili sto. U trenutnom export-u dostupni su ukupni skor, survival-derived stability skor i indikator pada.

Glava 5

Podaci i metodologija

Eksperiment koristi tri strogo odvojene uloge podataka. CMU i GaHu klipovi nemaju quality labela i koriste se samo za PCA/whitening reprezentacije. MuJoCo side-view klipovi nose simulatorom izveden ukupni skor i jedini su supervised podaci. Frontalni DisabledGait klipovi služe samo za proveru promene domena; njima se ne dodeljuje izmišljena ocena kvaliteta.

Svaki MuJoCo klip u manifestu sadrži identitet politike, checkpoint, scenario, seed i kameru. Svih šest scenarija jedne politike deli isti `split_group`. Time se sprečava da model u treningu vidi druge skoro identične snimke politike koja se kasnije pojavljuje u testu. Fiksna podela sadrži šest train, jednu validation i dve test politike. Dodatno se izvodi nested leave-one-policy-out evaluacija: svaka od devet politika jednom postaje spoljašnji test, dok se Ridge regularizacija bira isključivo na preostalim politikama.

Tabela 5.1: Uloge podataka u transfer eksperimentu

Izvor	Klipovi	Grupe	Uloga
CMU MuJoCo renderi	580	po CMU subjektu	neoznačena reprezentacija
GaHu realni side-view	395	44 subjekta	neoznačena reprezentacija
MuJoCo side-view	54	9 politika	supervised skor
DisabledGait frontalno	125	recording serije	OOD provera

Za svaki video biraju se dva deterministička vremenski normalizovana prozora od po 16 frejmova. Zamrznuti R3D-18, prethodno obučen na Kinetics-400, proizvodi po jedan 512-dimenzioni embedding; dva embeddinga se prosečno agregiraju i L2-normalizuju. PCA sa 64 komponente i whitening fituje se samo na 975 neoznačenih CMU i GaHu klipova i objašnjava 96.56% njihove varijanse. Na kraju se trenira mala Ridge glava za ukupni simulator-proxy skor.

1. Determinističko vremensko uzorkovanje dva prozora po klipu.

2. Ekstrakcija i cache-iranje zamrznutih R3D-18 embeddinga.
3. Fitovanje PCA/whitening transformacije samo na neoznačenim klipovima.
4. Izbor Ridge regularizacije grupisanom validation ili unutrašnjom CV petljom.
5. Evaluacija kroz MAE, RMSE, R^2 , Spearman i pairwise ranking accuracy.
6. Fitovanje deployment glave na svih 54 označenih klipova tek nakon evaluacije.

Tok nema policy leakage i ne koristi simulator state tokom inferencije. Pretrenirani backbone donosi opštu video reprezentaciju, ali se ne fine-tune-uje na malom labeled skupu, čime se ograničava rizik od overfitting-a.

Glava 6

Vizuelne osobine i motion representation

Najveća prednost ovog projekta je to što ne tretira video samo kao crnu kutiju. Umesto toga, gradi se medju-reprezentacija koja je ljudski razumljiva. Optički tok prikazuje gde i kako se telo kreće kroz kadar; residual flow odvaja opšti translacioni drift od relativnog kretanja delova tela; a PCA koeficijenti kondenzuju dominantne obrasce hoda u nekoliko brojeva po sekvenci.

Takva reprezentacija je korisna i sa inženjerske i sa prezentacione strane. Sa inženjerske strane, omogućava da se uoči gde model eventualno greši. Sa prezentacione strane, čini rad mnogo objašnjivijim od pristupa u kome bi postojao samo jedan duboki model i jedna izlazna brojka.

Na slici koja prikazuje optički tok može se videti intenzitet i smer lokalnog pomeranja. Heatmap temporalne energije dopunjuje taj pogled bez neopravdane tvrdnje da clip-level regresor daje frame-level dijagnozu.

Glava 7

Eksperimenti i rezultati

Izvedena su dva glavna eksperimenta nad istom leakage-safe podelom: klasični motion model i zamrznuti R3D-18 transfer model. Konstantni model koji vraća prosek train labela služi kao obavezna sanity provera. R3D-18 je treniran na NVIDIA RTX 2060 GPU-u; prvo izvlačenje 1154 video embeddinga trajalo je oko 16 minuta, dok ponavljanje sa popunjenim cache-om traje oko 25 sekundi.

Tabela 7.1: Poredjenje modela na istih 12 klipova iz dve izdvojene politike


Model	MAE	RMSE	R^2	Spearman	Ranking
R3D-18 transfer	12.35	15.49	0.660	0.877	0.773
Train-mean	22.17	29.48	-0.233	–	–
Klasični motion	35.84	43.64	-1.701	-0.252	0.439

R3D-18 smanjuje test MAE za 44.3% u odnosu na train-mean baseline i za 65.6% u odnosu na klasični motion model. Pozitivan R^2 i visoka Spearman korelacija pokazuju da model hvata i veličinu i poredak simulatorskih skorova na dve nevidjene politike. Ipak, fiksni test sadrži samo dve politike, pa jedan povoljan split nije dovoljan za jaku tvrdnju o generalizaciji.

Zato je izvedena nested policy evaluacija preko svih devet politika. Za svaku spoljašnju test politiku, Ridge hiperparametar bira se inner grupisanom validacijom bez pristupa toj politici. Agregirane out-of-fold metrike prikazane su u Tabeli 7.2.

Tabela 7.2: Nested leave-one-policy-out evaluacija R3D-18 modela

Nivo	N	MAE	RMSE	R^2	Spearman	Ranking
Klip	54	11.23	13.64	0.638	0.782	0.790
Policy prosek	9	5.84	6.99	0.830	0.983	0.972
Leave-one mean	9	15.59	19.07	-0.266	–	–



Slika 7.1: Levo: nested held-out prosek za svaku od devet politika. Desno: policy-level MAE R3D-18 modela i leave-one-policy mean baseline-a.

Za deployment glavu izabrano je $\alpha = 10$ grupisanom validacijom preko svih devet politika, nakon čega je glava fitovana na svih 54 označenih klipova. To ne menja evaluacione metrike, koje ostaju zasnovane isključivo na predikcijama iz prethodno odvojenih evaluacionih foldova.

Praktični izlaz sistema nije samo ocena jednog klipa. Za novu politiku model se učitava jednom, ocenjuje side-view snimke scenarija **forward**, **forward_slow**, **forward_fast**, **turn**, **lateral** i **diagonal**, a zatim vraća prosek, standardnu devijaciju, minimum, maksimum i scenario breakdown. Skor politike je validan jedino ako svih šest snimaka prodje camera i OOD proveru.


Glava 8

Vizuelni prikazi iz sistema

Klasična grana sistema ostaje korisna kao interpretabilni dijagnostički alat iako R3D-18 daje bolju regresiju ukupnog skora. Ona generiše optički tok i temporalnu heatmap-u, pa se obrazac kretanja može vizuelno proveriti. U nastavku su prikazani njeni izlazi nad jednim video klipom.



(a) Vizuelizacija optičkog toka



(b) Temporalna energija kretanja

Slika 8.1: Klasični motion dijagnostički prikazi za jedan klip.

Ovi izlazi omogućavaju proveru da li video sadrži očekivani obrazac kretanja, globalni drift ili nagli prekid. Oni nisu atribuciona metoda za R3D-18 i ne tvrde da objašnjavaju njegovu pojedinačnu predikciju. Takvo razdvajanje sprečava da koristan dijagnostički prikaz bude pogrešno predstavljen kao objašnjenje dubokog modela.

Kao end-to-end demonstracija policy komande, poznata politika P01 ocenjena je preko svih šest scenarija. Rezultat u Tabeli 8.1 služi isključivo kao funkcionalni sanity check, jer je P01 deo training kohorte; evaluacione tvrdnje i dalje dolaze samo iz held-out i nested rezultata.

Tabela 8.1: Primer policy-level izlaza za P01

	diag.	forward	fast	slow	lateral	turn	prosek
Skor	80.33	90.80	82.35	93.64	73.05	74.46	82.44

Standardna devijacija scenarija je 7.66, svih 6/6 snimaka je prošlo camera i OOD proveru, a policy skor je označen validnim.

Glava 9

Diskusija

Rezultati pokazuju da pretrenirana spatiotemporalna reprezentacija prenosi korisniji signal od ručno konstruisanih motion osobina. Dobitak nije samo posledica poređenja sa slabim klasičnim modelom: R3D-18 je znatno bolji i od train-mean baseline-a, a nested evaluacija zadržava pozitivan R^2 kada svaka politika redom postane nevidjeni test.

Ipak, devet politika nisu dovoljne za zaključak da je problem rešen. Šest scenarija jedne politike predstavljaju korelisane klipove, a ne šest nezavisnih subjekata. Nested rezultat je zato metodološki mnogo vredniji od random video split-a, ali interval nezvesnosti ostaje širok. Dodatno, ciljni skor je scenario-relative simulaciona kompozicija stabilnosti, praćenja, uspravnosti i glatkoće, a ne ekspertna ocena ljudskog hoda.

Promena domena je vidljiva i numerički. Prag udaljenosti trening domena je 1.661, dok frontalni DisabledGait klipovi imaju medijanu 2.307 i 95. percentil 2.559. To je dobar rezultat za safety logiku: sistem prepoznaje da frontalni realni snimci nisu podržani. Nije, međutim, dokaz da deployment model dobro ocenjuje realne ljude. Takvim klipovima se zato prikazuje upozorenje, a `clinical_score_valid` uvek ostaje false.

Moja procena je da je R3D-18 v1 dovoljno dobar za izbor simulacionih klipova, rangiranje novih walker politika i proveru ostatka pipeline-a. Nije dovoljno dobar za tvrdnju o kvalitetu ljudskog hoda, invaliditetu ili rehabilitaciji.

Glava 10

Ograničenja i budući rad

Najvažnije ograničenje rada jeste to što ciljni skor potiče iz simulatora, a ne iz nezavisne ljudske ili kliničke procene. Zbog toga model zapravo ne uči “kvalitet hoda” u opštem smislu, već aproksimaciju jedne specifične definicije kvaliteta koju je nametnuo izvor podataka.

Drugo ograničenje je što RGB video ne nosi direktnu informaciju o kontaktima, silama i unutrašnjoj stabilnosti kontrolera. Neke nepravilnosti se mogu videti, ali neke ostaju skrivene. To posebno pogađa komponente koje u sebi imaju jači dinamički ili kontaktni karakter.

Treće ograničenje je veličina i homogenost skupa. Iako postoji više scenarija, aktivni side-view dataset je i dalje relativno mali. Za bolju procenu opštosti modela bilo bi korisno imati više klipova, više politika i odvojene eksperimente po kameri, scenariju i tipu hoda.

Najvažniji pravci budućeg rada su:

- zamrznuti v1 protokol testirati na više novih walker politika;
- prikupiti realne side-view snimke sa više nezavisnih ekspertnih ocenjivača;
- odvojiti subjekte i lokacije između treninga i finalnog testa;
- tek sa većim labeled skupom kontrolisano fine-tune-ovati poslednji R3D blok;
- kalibrisati uncertainty i unapred definisati kriterijum odbijanja OOD ulaza.

Glava 11

Zaključak

U radu je predstavljen kompletan pipeline za vizuelnu procenu simulatorom izvedenog kvaliteta hoda iz RGB videa. Klasična Szeliski-inspirisana grana obezbeđuje interpretabilne motion prikaze, dok zamrznuti R3D-18 transfer model daje znatno bolju numeričku procenu ukupnog skora.

Na fiksnom clip-level policy-held-out testu R3D-18 postiže MAE 12.35. Nested evaluacija policy proseka preko svih devet politika daje MAE 5.84, $R^2 = 0.830$ i Spearman 0.983, naspram MAE 15.59 za leave-one-policy mean baseline. Time je pokazano da spoljni RGB video sadrži koristan signal za aproksimaciju definisanog simulacionog target-a. Leakage-safe podela, odvojeno biranje hiperparametara i OOD upozorenja čine rezultat reproduktivnim i metodološki odbranjivim.

Glavno ograničenje ostaje semantika labela i mali broj nezavisnih politika. Zato je konačni zaključak precizan: model je uspešan v1 istraživački baseline za simulirane side-view sekvence, ali nije validiran za medicinsku ili kliničku procenu ljudskog hoda.

Literatura

1. Richard Szeliski, *Computer Vision: Algorithms and Applications*, draft version, September 3, 2010.
2. Gunnar Farneback, *Two-Frame Motion Estimation Based on Polynomial Expansion*, 2003.
3. PECoP: *Parameter Efficient Continual Pretraining for Action Quality Assessment*, WACV 2024.
4. Du Tran, Heng Wang, Lorenzo Torresani, Jamie Ray, Yann LeCun i Manohar Paluri, *A Closer Look at Spatiotemporal Convolutions for Action Recognition*, CVPR 2018.
5. Torchvision R3D-18 video model sa Kinetics-400 V1 pretreniranim težinama, <https://docs.pytorch.org/vision/stable/models.html>.
6. CARE-PD repository, inspected as conceptual reference for AQA and rehabilitation scoring.
7. Projekat `mujoco-bipedal-joystick-walker`, korišćen kao izvor renderovanih sekvenci i label signala.
8. Resty Wulanningrum, Anik Nur Handayani i Heru Wahyu Herwanto, *Disabled-Gait: Gait Dataset of Normal People and People with Disabilities*, Mendeley Data, version 2, 2024, DOI: 10.17632/v6hy35ydch.2.
9. Edward Guillen Pinto, Leonardo Ramirez Lopez i Carlos Ramos Linares, *GaHu-Video: Parametrization System for Human Gait Recognition*, Mendeley Data, version 1, 2020, DOI: 10.17632/gprg4s73v4.1.
10. **Mogući dodatni skup podataka:** OU-ISIR Gait Database, Treadmill Dataset, Osaka University. Pristup zahteva potpisan institucionalni release agreement i posebno odobrenje; skup je zato evidentiran samo kao kandidat za budući rad.