



Univerzitet u Beogradu
Elektrotehnički fakultet
Katedra za Signale i sisteme



Vizuelna procena kvaliteta hoda MuJoCo politika iz RGB videa

Aleksa Mojsić

25/3319

Beograd, avgust 2026.

Sadržaj

1	UVOD	1
2	OSNOVE KOMPJUTERSKE VIZIJE ZA ANALIZU HODA	3
2.1	Poravnanje slika i procena translacije	3
2.2	Optički tok	5
2.2.1	Linearizacija i brightness constancy jednačina	6
2.2.2	Regularizacija optičkog toka	7
2.3	Naučeni modeli kretanja	7
2.4	SVD i PCA redukcija dimenzionalnosti	8
2.5	Vremenska struktura i Furijeova analiza	10
2.6	Najmanji kvadrati i regularizovana regresija	10
2.7	Veza teorije sa implementacijom	11
3	MAŠINSKO UČENJE ZA PROCENU KVALITETA POKRETA	12
3.1	Nadgledano učenje i regresija	12
3.1.1	Normalizacija i PCA	12
3.1.2	Ridge regresija	13
3.2	Duboko učenje	13
3.2.1	R3D-18 model	13
3.2.2	Transfer učenje	14
3.3	Metrike evaluacije	14
4	KREIRANJE MODELA ZA VIZUELNU PROCENU KVALITETA HODA	15
4.1	Analiza podataka	15
4.2	Definicija skora	17
4.3	Proces kreiranja modela	17

4.3.1	Klasični model	18
4.3.2	R3D-18 transfer model	18
4.4	Rezultati	19
4.5	Statistička pozadina rezultata	20
5	PRIMENA MODELA NA WALKER POLITIKE	21
5.1	Vizuelni prikazi	21
5.2	Policy-level ocenjivanje	23
5.3	Promena domena i OOD provera	24
6	OGRANIČENJA I BUDUĆI RAD	25
7	ZAKLJUČAK	26
	LITERATURA	27

1 UVOD

Kompjuterska vizija se koristi za izvlačenje informacija iz slika i video sekvenci, a analiza kretanja predstavlja jedan od problema gde pojedinačan frejm često nije dovoljan, posebno kada se posmatra hod jer jedna slika može pokazati položaj noge ili tela u jednom trenutku ali ne i ritam, promenu položaja kroz vreme, klizanje ili to da li se isti obrazac ponavlja. Kod hoda je to posebno izraženo. Zbog toga je za procenu kvaliteta hoda potreban video.

Procena kvaliteta akcije, odnosno AQA (Action Quality Assessment), pokušava da na osnovu video sekvence odredi koliko je neki pokret dobro izveden [18,20]. Ovakvi sistemi postoje za sportske pokrete, rehabilitacione vežbe i procenu ljudskog hoda, dok je ovde ideja malo drugačija. Posmatra se humanoidni agent koji hoda u MuJoCo simulatoru. Cilj nije da se odredi medicinska ocena hoda, nego da se proceni skor koji već postoji u simulatoru i koji opisuje uspešnost politike. PECoP¹ predstavlja jedan savremen primer video AQA pristupa [3], dok CARE-PD² pokazuje sličnu ideju procene hoda u drugom domenu [6].

MuJoCo projekat koji je korišćen kao izvor podataka sadrži različite walker politike i scenarije hoda [7]. Simulator može da da dosta preciznih internih signala, kontakte, podatke o padu, stanje agenta i druge veličine, međutim ako bi se sve to dalo i modelu za procenu onda problem kompjuterske vizije praktično više ne bi postojao, jer bi model samo ponovo računao nešto što simulator već zna. Zato se simulator koristi za pravljenje labela, dok model tokom inferencije vidi samo RGB video.

Postavljaju se dva glavna pitanja: „Da li se ukupni kvalitet MuJoCo hoda može dovoljno dobro proceniti samo iz spoljnog videa”? i „Da li klasične metode analize kretanja mogu da daju dovoljno dobru reprezentaciju, ili je neophodna prethodno obučena video mreža”?

Prvi pristup u radu zasniva se na klasičnoj analizi kretanja. Iz frejmova se računa optički tok, zatim se uklanja deo dominantne translacije i polja kretanja se prevode u kom-

¹PECoP je pristup za procenu kvaliteta pokreta iz videa koji koristi već pretrenirane video modele i dodatno ih prilagođava novom zadatku uz mali broj novih parametara. U ovom radu služi kao primer modernog AQA pristupa.

²CARE-PD je sistem za procenu hoda i motoričkih simptoma iz video snimaka ljudi, u kontekstu Parkinsonove bolesti. Ovde ga navodimo kao primer srodnog problema procene hoda, ali u realnom kliničkom domenu.

paktnu PCA/SVD reprezentaciju³. Ovakav pristup je inspirisan literaturom o proceni kretanja i naučenim modelima kretanja iz knjige Richarda Szeliskog [1]. Drugi pristup koristi R3D-18⁴, odnosno 3D konvolucionu mrežu za video, ali bez fine-tune-ovanja celog backbone-a na veoma malom skupu podataka [4,17].

Ovaj rad je organizovan na sledeći način. U drugom poglavlju dat je pregled osnovnih pojmova kompjuterske vizije koji su potrebni za analizu hoda, sa fokusom na translaciono poravnanje, optički tok i naučene modele kretanja. Treće poglavlje prikazuje deo mašinskog učenja koji je direktno potreban za ovaj problem, odnosno regresiju, PCA i transfer učenje⁵. U četvrtom poglavlju je prikazana praktična izrada modela, analiza podataka, definicija skora i proces kreiranja oba sistema. Rezultati se takođe prvo posmatraju u tom okviru, a u petom poglavlju se detaljnije prikazuje primena na walker politike, vizuelni izlazi i policy-level ocenjivanje. Šesto poglavlje obuhvata ograničenja, promenu domena i budući rad. Sedmo poglavlje predstavlja zaključak.

³PCA (Principal Component Analysis) i SVD (Singular Value Decomposition) su standardne metode linearne algebre za smanjenje dimenzionalnosti i izdvajanje najvažnijih obrazaca u podacima. U ovom radu služe da se složena polja kretanja prevedu u kraći i pogodniji vektor osobina.

⁴R3D-18 je 3D konvoluciona neuronska mreža za video. Za razliku od obične 2D mreže nad slikama, ona istovremeno obrađuje prostor i vreme, pa može da uči obrasce pokreta kroz više uzastopnih frejmova.

⁵Transfer učenje znači da se model koji je već naučio korisne obrasce na velikom skupu podataka koristi kao početna osnova za novi, drugačiji ali srodan zadatak.

2 OSNOVE KOMPJUTERSKE VIZIJE ZA ANALIZU HODA

Kod procene hoda iz video snimka nije dovoljna samo informacija iz jednog frejma. Položaj noge ili trupa u jednom trenutku može da izgleda sasvim normalno, dok se nepravilnost vidi tek kada se posmatra promena kroz vreme. Zbog toga se u ovom radu video posmatra kao niz slika između kojih treba proceniti kretanje. Szeliski probleme ovog tipa razmatra kroz poravnanje slika, parametarske modele kretanja, optički tok i naučene modele kretanja [1]. Ovakva podela je direktno primenljiva i na hod, jer je cilj prvo opisati kretanje, a tek zatim iz tog opisa proceniti kvalitet.

2.1 Poravnanje slika i procena translacije

Najjednostavniji oblik procene kretanja je translaciono poravnanje dve slike. Pretpostavlja se da se sadržaj iz prve slike nalazi u drugoj slici pomeren za vektor $\mathbf{u} = (u, v)$. Za dati pomeraj može se meriti suma kvadrata razlika odgovarajućih piksela, odnosno SSD kriterijum [1, Sec. 8.1]:

$$E_{SSD}(\mathbf{u}) = \sum_i [I_1(\mathbf{x}_i + \mathbf{u}) - I_0(\mathbf{x}_i)]^2. \quad (2.1)$$

Ovde je I_0 prvi frejm, I_1 sledeći frejm, $\mathbf{x}_i$ pozicija piksela, a $\mathbf{u}$ procenjeni pomeraj. Razlika

$$e_i = I_1(\mathbf{x}_i + \mathbf{u}) - I_0(\mathbf{x}_i) \quad (2.2)$$

predstavlja rezidualnu grešku. Osnovna pretpostavka je da odgovarajuće tačke između dva bliska frejma zadržavaju približno isti intenzitet. Szeliski ovu pretpostavku navodi kao *brightness constancy* [1, p. 384]. Naravno, u realnom videu ona nije savršena. Promena osvetljenja, blur, senke ili refleksije mogu promeniti vrednost piksela i bez fizičkog pomeranja objekta.


Kod humanoidnog hoda ovo je važno jer se ceo robot pomera kroz kadar. Ako se po-

smatra samo sirovi optički tok, veliki deo vektora predstavlja zajedničko globalno pomeranje tela, a ne relativno kretanje nogu. Zbog toga se u praktičnom delu koristi i body-centered residual flow, gde se dominantna translaciona komponenta proceni i ukloni pre formiranja završnih osobina.

Za veća pomeranja direktna pretraga na punoj rezoluciji postaje skupa i može biti nepouzdana. Szeliski zato opisuje hijerarhijski *coarse-to-fine* pristup [1, Sec. 8.1.1]. Slika se prvo smanjuje u piramidi, pomeraj se proceni na grubom nivou, a zatim se ta procena prenosi na finiji nivo. Za prelaz na sledeći finiji nivo procena pomeraja se približno skalira kao

$$\hat{\mathbf{u}}^{(l-1)} \leftarrow 2\mathbf{u}^{(l)}. \quad (2.3)$$

Ovo omogućava da se veliki pokreti prvo vide kao manji pokreti na nižoj rezoluciji, posle čega se rezultat postepeno precizira.



Slika 2.1: Primeri procene kretanja i optičkog toka. Preuzeto iz [1], Slika 8.1, str. 382.

2.2 Optički tok

Optički tok predstavlja procenu prividnog pomeranja u ravni slike. Za razliku od jedne globalne translacije, kod gustog optičkog toka procenjuje se poseban vektor pomeranja za veliki broj piksela, praktično za ceo kadar. Szeliski opšti SSD oblik za optički tok piše kao [1, Sec. 8.4]

$$E_{\text{OF}}(\{\mathbf{u}_i\}) = \sum_i [I_1(\mathbf{x}_i + \mathbf{u}_i) - I_0(\mathbf{x}_i)]^2. \quad (2.4)$$

Ovde svaki piksel ima svoj pomeraj $\mathbf{u}_i$. To odmah pravi problem, jer broj nepoznatih veličina postaje veoma veliki. Zbog toga se lokalne metode oslanjaju na prozore i pretpostavku


da susedni pikseli imaju slično kretanje, dok globalne metode dodaju uslov glatkoće polja kretanja.

2.2.1 Linearizacija i brightness constancy jednačina

Za male promene pomeraja može se koristiti Taylorov razvoj intenziteta slike. Lucas–Kanade pristup linearizuje funkciju slike oko trenutne procene pomeraja [1, Sec. 8.1.3; 11]. Na taj način se dobija poznata jednačina optičkog toka

$$I_x u + I_y v + I_t = 0, \quad (2.5)$$

gde su I_x i I_y prostorni izvodi intenziteta, I_t vremenski izvod, a u i v horizontalna i vertikalna komponenta brzine odnosno pomeraja. Jednačina pokazuje da se promena intenziteta može povezati sa kretanjem kroz gradijent slike. Međutim, jedna jednačina nije dovoljna da jednoznačno odredi dve komponente kretanja. Zato se koriste dodatne pretpostavke i informacije iz okoline piksela.



Slika 2.2: Taylorova aproksimacija i inkrementalna korekcija optičkog toka. Preuzeto iz [1], Slika 8.2, str. 392.


Kada se linearizovani problem posmatra u lokalnom prozoru, dobija se sistem normalnih jednačina

$$\mathbf{A} \Delta \mathbf{u} = \mathbf{b}, \quad (2.6)$$

pri čemu je

$$\mathbf{A} = \sum_i \mathbf{J}_i^T \mathbf{J}_i, \quad \mathbf{b} = - \sum_i e_i \mathbf{J}_i^T. \quad (2.7)$$

Matrica $\mathbf{A}$ sadrži informaciju o lokalnoj strukturi gradijenata. Ako u regionu nema dovoljno tekstone ili postoji samo jaka ivica, sistem može biti loše uslovljen. To je poznati *aperture problem*. U slučaju jedne ivice pouzdano se vidi samo komponenta kretanja normalna na ivicu, dok je komponenta duž ivice neodređena [1, pp. 395–397].



Slika 2.3: Aperture problem za teksturisani region, ivicu i region bez tekstore. Preuzeto iz [1], Slika 8.3, str. 395.

Ovo ograničenje je bitno i u našem slučaju. Površine MuJoCo modela mogu biti gotovo jednoboje, pa deo toka na trupu ili ekstremitetima može biti manje pouzdan nego tok na ivicama tela. Zbog toga flow ne treba tumačiti kao direktno i potpuno tačno merenje fizičke brzine robota. On je vizuelna reprezentacija kretanja iz koje se dalje izvlače osobine.

2.2.2 Regularizacija optičkog toka

Szeliski prikazuje i globalni pristup gde se brightness constancy greška posmatra preko cele slike. Ovakav pristup je klasično povezan sa Horn–Schunck formulacijom optičkog toka [12]. Za linearizovani slučaj data-term može da se napiše kao [1, Eq. 8.70]

$$E_{\text{data}} = \int (I_x u + I_y v + I_t)^2 dx dy. \quad (2.8)$$

Sam data-term nije dovoljan jer je problem optičkog toka potodređen. Zato se dodaje penal koji favorizuje glatko rešenje. U opštem obliku regularizacije iz knjige [1, Sec. 3.7.1] ciljna funkcija je

$$E = E_d + \lambda E_s, \quad (2.9)$$

gde E_d meri slaganje sa podacima, E_s meri neželjenu neregularnost ili neglatkost, a λ određuje odnos ova dva zahteva. Kod toka se ovakva ideja koristi da susedne procene ne menjaju smer i intenzitet potpuno proizvoljno. Sa druge strane, prejaka regularizacija može da izravna stvarne diskontinuitete kretanja, na primer granicu između noge i pozadine.

2.3 Naučeni modeli kretanja


Sirovo polje optičkog toka je veoma visoke dimenzionalnosti. Za svaki frejm postoje horizontalna i vertikalna komponenta na velikom broju piksela. Ako se takva polja koriste

direktno, broj karakteristika brzo postaje mnogo veći od broja dostupnih označenih klipova. Zato je korisno pronaći manji broj dominantnih obrazaca kretanja.

Szeliski u odeljku *Learned motion models* opisuje upravo ovakav postupak. Iz trening video sekvenci se prvo računaju gusta polja kretanja, zatim se polja slažu u skup i nad njima se radi singularna dekompozicija. Dobijeni singularni vektori predstavljaju bazna polja kretanja, a novo polje se opisuje njihovom linearnom kombinacijom [1, Sec. 8.2.2; 13]:

$$\mathbf{u}(\mathbf{x}) = \sum_k a_k \mathbf{v}_k(\mathbf{x}). \quad (2.10)$$

Koeficijenti a_k govore koliko je određeni bazni obrazac prisutan u datom trenutku. Posebno je značajno što je primer u knjizi urađen baš na sekvenci hodanja. Na slici su prikazana bazna flow polja, ali i promena njihovih koeficijenata kroz vreme. To je praktično ista ideja koju koristi klasični pipeline ovog rada, samo se kasnije iz vremenskih nizova koeficijenata računaju dodatne osobine.



Slika 2.4: Naučena bazna polja kretanja i vremenski koeficijenti na walking sekvenci. Preuzeto iz [1], Slika 8.6, str. 404.

2.4 SVD i PCA redukcija dimenzionalnosti


Matematička osnova prethodnog postupka je singularna dekompozicija. Za proizvoljnu realnu matricu $\mathbf{A}$ važi [1, App. A.1.1]

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T. \quad (2.11)$$

Kolone matrica $\mathbf{U}$ i $\mathbf{V}$ su ortonormirani singularni vektori, dok dijagonalna matrica $\mathbf{\Sigma}$ sadrži singularne vrednosti

$$\sigma_0 \geq \sigma_1 \geq \dots \geq \sigma_{p-1} \geq 0. \quad (2.12)$$

Ako se zadrži samo prvih r komponenti, dobija se najbolja aproksimacija matrice datog ranga u least-squares smislu [1, Eq. A.5]. To je razlog zbog kojeg mali broj komponenti može da sačuva najveći deo strukture iz velikog vektora optičkog toka.



Slika 2.5: Geometrijsko tumačenje SVD/PCA transformacije. Preuzeto iz [1], Slika A.1, str. 738.

PCA se može formulisti preko kovarijacione matrice [14]. Za skup vektora $\mathbf{x}_i$ sa srednjom vrednošću $\bar{\mathbf{x}}$ kovarijaciona matrica je

$$\mathbf{C} = \frac{1}{n} \sum_i (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^T. \quad (2.13)$$

Svojstveni vektori matrice $\mathbf{C}$ daju glavne pravce varijacije, dok svojstvene vrednosti određuju količinu varijanse duž tih pravaca. Projekcija novog primera na i -tu PCA komponentu može da se napiše kao [1, Eq. 14.11]

$$a_i = (\mathbf{x} - \mathbf{m}) \cdot \mathbf{u}_i. \quad (2.14)$$

U ovom radu je bitna i whitening transformacija, jer se ona koristi nad R3D embedding prostorom. Szeliski je zapisuje kao [1, Eq. 14.15]

$$\hat{\mathbf{U}} = \mathbf{U}\mathbf{\Lambda}^{-1/2}. \quad (2.15)$$

Intuitivno, običan PCA samo rotira koordinatni sistem u pravce najveće varijanse, dok whitening dodatno skalira komponente prema njihovoj varijansi. Komponente sa vrlo velikom varijansom se smanjuju, a one sa manjom varijansom postaju uporedivije. U radu se ova transformacija fituje isključivo na trening odnosno neoznačenom reprezentacionom skupu, bez korišćenja test politika.

2.5 Vremenska struktura i Furijeova analiza


Hod je približno periodičan proces. Nije uvek potpuno periodičan, posebno kod skretanja ili promene komande, ali se smene oslonca i zamaha nogu ponavljaju. Zbog toga se vremenski nizovi PCA koeficijenta mogu analizirati i u frekvencijskom domenu.

Diskretna Furijeova transformacija signala dužine N u Szeliskom je data kao [1, Eq. 3.54]

$$H(k) = \frac{1}{N} \sum_{x=0}^{N-1} h(x) e^{-j2\pi kx/N}. \quad (2.16)$$

Transformacija razdvaja signal na komponente različitih učestanosti. U pravilnom periodičnom hodu veći deo energije može da bude koncentrisan oko dominantne frekvencije koraka i njenih harmonika. Kod nestabilnog ili neregularnog pokreta energija može biti raspoređena šire. Ovo nije samostalna mera kvaliteta, ali predstavlja dodatnu karakteristiku modela.

Szeliski navodi i Parsevalovu teoremu, prema kojoj je ukupna energija signala jednaka energiji njegove Furijeove reprezentacije. Zbog toga je opravdano koristiti spektralnu energiju i odnos energije u različitim frekvencijskim opsezima kao sažete osobine vremenskog signala.



Slika 2.6: Osnovna interpretacija Furijeove transformacije preko amplitude i faze sinusoidnog signala. Preuzeto iz [1], Slika 3.24, str. 133.

2.6 Najmanji kvadrati i regularizovana regresija

Kada se video prevede u konačan vektor osobina, potrebno je proceniti numerički gait score. Knjiga daje opšti oblik linearnog problema najmanjih kvadrata [1, App. A.2]

$$E_{LLS} = \|\mathbf{Ax} - \mathbf{b}\|^2, \quad (2.17)$$

čije normalne jednačine imaju oblik

$$(\mathbf{A}^T \mathbf{A})\mathbf{x} = \mathbf{A}^T \mathbf{b}. \quad (2.18)$$

U praktičnom delu se koristi Ridge regresija, gde se pored greške uvodi i L2 penal nad veličinom koeficijenata. Szeliski ne predstavlja Ridge kao zaseban model u formi u kojoj se koristi u scikit-learn biblioteci, ali teorijska ideja odgovara opštem principu regularizacije iz jednačine 2.9: model treba da prati podatke, ali se istovremeno kažnjava previše složeno ili nestabilno rešenje. Originalna formulacija Ridge regresije data je u [15].

2.7 Veza teorije sa implementacijom

Klasični deo sistema može se povezati sa prethodnom teorijom u nekoliko koraka. Prvo se video dekodira i frejmovi se vremenski normalizuju. Zatim se procenjuje gusti optički tok. Dominantno globalno pomeranje se umanjuje poravnanjem, posle čega se flow polja svode na manju dimenziju i slažu u matricu. PCA/SVD daje mali broj baznih pravaca kretanja, a koeficijenti tih pravaca se posmatraju kroz vreme. Iz njih se računaju statističke i frekvencijske osobine, koje zatim ulaze u regresioni model.

Ovim se dobijaju dve stvari. Prvo, količina podataka se smanjuje tako da model može da radi i kada postoji mali broj nezavisnih walker politika. Drugo, klasična reprezentacija ostaje dovoljno pregledna da se mogu nacrtati flow polja, bazni pravci i promena koeficijenata kroz vreme. To je razlog zbog kojeg je ovaj pristup zadržan u radu iako je R3D-18 transfer model numerički bolji.

3 MAŠINSKO UČENJE ZA PROCENU KVALITETA PO-KRETA

Mašinsko učenje se u ovom radu koristi zato što ne postoji jednostavna jednačina koja direktno prevodi optički tok ili video embedding u ukupni simulator skor. Postoji skup klipova za koje je ciljna vrednost poznata i traži se funkcija koja će tu vrednost proceniti za novi klip. To predstavlja problem nadgledanog učenja, preciznije regresije.

Važno je da je broj označenih primera mali. Postoji 54 video klipa, međutim to nisu 54 potpuno nezavisna slučaja jer šest scenarija dolazi od iste politike, isti kontroler proizvodi slične karakteristike u više snimaka i zbog toga bi random podela klipova vrlo lako stavila praktično istu politiku i u trening i u test. Rezultat bi onda izgledao bolje. Ali to nije pitanje koje nas zanima.

3.1 Nadgledano učenje i regresija

Kod regresije cilj je numerička vrednost. Ovde je to ukupni skor u opsegu od 0 do 100. Model dobija vektor osobina x i pokušava da proceni $\hat{y}$ koji je što bliži stvarnom skor y . Za razliku od klasifikacije, nema nekoliko diskretnih klasa kao „dobar” i „loš” hod, već se čuva kontinualna ocena.

Za jednostavan baseline korišćena je Ridge regresija. To je linearni model sa L2 regularizacijom [15]. Regularizacija je značajna zato što broj vizuelnih osobina može biti velik u odnosu na broj nezavisnih trening politika, pa običan linearni model lako može da se prilagodi šumu.

3.1.1 Normalizacija i PCA

PCA se u radu koristi na dva mesta, ali ne sa istom svrhom [14]. U klasičnom modelu PCA/SVD predstavlja motion basis nad osobinama optičkog toka. U transfer modelu PCA sa whitening transformacijom radi nad R3D-18 embedding prostorom. U oba slučaja transformacija mora da se fituje bez gledanja test podataka.

Ovo je jednostavno pravilo, ali je lako pogrešiti. Ako bi PCA ili scaler bio fitovan

na svim klipovima pre podele, test skup bi uticao na samu reprezentaciju. Takav rezultat bi bio oblik data leakage-a. Zato su fitovanje reprezentacije i izbor hiperparametara odvojeni od finalne test politike.

3.1.2 Ridge regresija

Ridge regresija minimizuje grešku predikcije uz dodatni penal nad veličinom koeficijenta. Parametar α određuje jačinu regularizacije. Prevelika vrednost može da napravi model koji je suviše jednostavan, dok premala vrednost može da dovede do prenaučnosti.

Kod fiksne podele α se bira na validation politici, a u nested leave-one-policy-out evaluaciji bira se u unutrašnjoj petlji bez korišćenja spoljašnje test politike. Na kraju je za deployment glavu izabrano $\alpha = 10$ grupisanom validacijom preko svih devet politika. Ovo fitovanje na svih 54 klipa se koristi tek nakon završene evaluacije i ne menja prethodno izračunate test metrike.

3.2 Duboko učenje

Duboko učenje za video najčešće obrađuje i prostornu i vremensku informaciju. Kod obične 2D konvolucije filter se pomera po visini i širini slike. Kod 3D konvolucije postoji i vremenska dimenzija, pa model može da uči obrasce koji se pojavljuju kroz više uzastopnih frejmova.

U ovom radu nije trenirana velika video mreža od nule. Takav pristup nema smisla sa 54 označena klipa. Umesto toga koristi se već prethodno obučen model i iz njega se izvlače karakteristike.

3.2.1 R3D-18 model

R3D-18 je model zasnovan na spatiotemporalnim konvolucijama [4]. Korišćena je Torchvision varijanta sa Kinetics-400 V1 pretreniranim težinama [5,17]. Backbone ostaje zamrznut, što znači da se njegovi parametri ne prilagođavaju na 54 MuJoCo klipa.

Za svaki video biraju se dva deterministička vremenski normalizovana prozora od po 16 frejmova. Za svaki prozor R3D-18 daje embedding od 512 dimenzija. Dva embeddinga se prosečno agregiraju i L2-normalizuju. Posle toga se primenjuje PCA whitening sa 64 komponente.

3.2.2 Transfer učenje

Transfer učenje znači da se reprezentacija naučena na jednom većem zadatku koristi kao početna reprezentacija za novi zadatak [16]. Kinetics-400 naravno nije skup humanoidnih MuJoCo politika i gotov R3D-18 ne zna šta je naš composite score, niti šta mi smatramo dobrim hodom, ali je već video veliki broj pokreta i naučio spatiotemporalne obrasce koji mogu da budu korisni i kada se zadatak promeni. To je deo koji pokušavamo da iskoristimo.

PCA/whitening se dodatno fituje samo na 975 neoznačenih walking klipova, 580 CMU MuJoCo rendera i 395 realnih GaHu snimaka. Ovi klipovi nemaju quality labela. Na taj način se embedding prostor približava lokalnom walking domenu bez korišćenja ocene kvaliteta.

3.3 Metrike evaluacije

MAE predstavlja prosečnu apsolutnu grešku između stvarnog i predviđenog skora. RMSE jače kažnjava velike greške. R^2 pokazuje koliko varijanse ciljne promenljive model objašnjava u odnosu na konstantni model, dok Spearman korelacija meri slaganje poretka. Za ovaj projekat je Spearman važan zato što je jedna praktična upotreba rangiranje walker politika.

Pored toga se koristi pairwise ranking accuracy. Ona proverava da li je za par klipova pravilno procenjeno koji treba da ima veći skor. Nije dovoljno da model samo pogodi prosečnu vrednost. Ako treba da se koristi za izbor između dve politike, poredak je takođe bitan.

4 KREIRANJE MODELA ZA VIZUELNU PROCENU KVALITETA HODA

U praktičnom delu rada prvo su organizovani dostupni video snimci, zatim je definisan target i napravljena podela koja ne meša iste politike između treninga i testa. Posle toga su napravljena dva pipeline-a. Jedan koristi ručno izvedene motion karakteristike, a drugi prethodno obučenu video reprezentaciju.

4.1 Analiza podataka

Eksperiment koristi četiri izvora podataka, ali oni nemaju istu ulogu i to je potrebno razdvojiti. CMU i GaHu klipovi služe samo za neoznačenu reprezentaciju, MuJoCo side-view klipovi nose simulatorom izvedenu ocenu i jedini predstavljaju supervised deo, dok se DisabledGait koristi samo kao provera promene domena, odnosno da se vidi kako reprezentacija reaguje kada dobije frontalne realne snimke koje nije trebalo da ocenjuje. DisabledGait klipovima nije dodeljivana izmišljena quality ocena [8].

Tabela 4.1 prikazuje tačan broj klipova i njihovu ulogu.

Tabela 4.1: Uloge podataka u eksperimentu


Izvor	Klipovi	Grupe	Uloga
CMU MuJoCo renderi	580	po CMU subjektu	neoznačena reprezentacija
GaHu realni side-view	395	44 subjekta	neoznačena reprezentacija
MuJoCo side-view	54	9 politika	supervised skor
DisabledGait frontalno	125	recording serije	OOD provera

GaHu predstavlja realne side-view video sekvence ljudskog hoda [9]. Na slici 4.1 prikazan je primer klipa korišćenog u neoznačenom delu. Ovaj video nema target skora i ne koristi se kao supervised primer.



Slika 4.1: Primer realnog GaHu side-view walking klipa [9].

Drugi veliki neoznačeni izvor su CMU sekvence koje su retargetovane i renderovane kroz MuJoCo. Primer je prikazan na slici 4.2. Ovde je izgled robota bliži supervised domenu, dok je GaHu koristan zato što sadrži stvarne video karakteristike.



Slika 4.2: Primer CMU walking sekvence renderovane u MuJoCo.

Supervised skup sadrži 54 side-view klipa, odnosno devet politika sa šest scenarija. Svaki manifest red sadrži identitet politike, checkpoint, scenario, seed i kameru. Svih šest scenarija jedne politike deli isti `split_group`. Fiksna podela sadrži šest train politika, jednu validation i dve test politike.

4.2 Definicija skora

Ukupni skor je preuzet direktno iz walker export-a [7] i preslikan iz $[0, 1]$ u $[0, 100]$. Izvorna definicija je scenario-relative težinski prosek stabilnosti, praćenja, uspravnosti i glatkoće:

$$\begin{aligned} \text{composite} = & 0.40 \cdot \text{stability} + 0.30 \cdot \text{tracking} \\ & + 0.20 \cdot \text{upright} + 0.10 \cdot \text{smoothness}. \end{aligned}$$

Ovo je važno ograničenje rada. Model ne uči neku univerzalnu definiciju prirodnog hoda. On pokušava da aproksimira konkretnu ocenu koju je napravio simulator evaluation pipeline. Takav target je koristan jer je dosledan i može se automatski dobiti za veliki broj klipova, ali nije isto što i ljudska procena.

Kompaktni video manifest nema sve originalne normalizovane komponente, kao ni `mean_action_rate_norm`. Zbog toga one nisu ponovo rekonstruisane lokalnim min-max skaliranjem, jer bi se tako promenila definicija target-a. Dostupni su ukupni skor, survival-derived stability i indikator pada.

U Tabeli 4.2 prikazano je šta se stvarno koristi, a šta ostaje nedostupno.

Tabela 4.2: Dostupne komponente i tumačenje skora

Komponenta	Značenje
Overall	Sto puta izvorni <code>composite_score</code> .
Stability	Sto puta udeo sekvence pre prvog pada.
Fall	Reset, terminalni događaj ili survival manji od jedan.
Ostale komponente	Nedostupne u trenutnom export-u; ostaju prazne.

Nedostupne vrednosti nisu zamenjene nulom. To bi bilo zgodno za programiranje, ali bi imalo pogrešno značenje i model bi učio veštačke labele.

4.3 Proces kreiranja modela

Priprema podataka i treniranje su odvojeni. Prvo se prave manifesti, proveravaju video fajlovi i definiše grupisana podela. Posle toga klasična i transfer grana koriste iste supervised foldove, tako da poređenje nije napravljeno na različitim test skupovima.

Glavni delovi repozitorijuma prikazani su u Tabeli 4.3.

Tabela 4.3: Glavni delovi repozitorijuma i njihova uloga

Putanja	Uloga u sistemu
MUJOCo_videos_better/	Side i front-oblique MuJoCo renderi.
CMU_reference_videos/	BVH walking reference i MuJoCo renderi.
datasets/gahu/	Realni side-view walking klipovi bez quality labela.
datasets/disabled_gait/	Frontalni realni klipovi samo za OOD proveru.
data/manifests/	CSV manifesti i train/val/test podele.
src/gait_aqa/vision/	Preprocessing, optički tok, poravnanje i motion basis.
src/gait_aqa/training/	Klasični i R3D-18 transfer trening.
output/	Modeli, cache, predikcije i vizuelni izlazi.
reports/	Izveštaj, dokumentacija i LaTeX izvor.

4.3.1 Klasični model

Klasični pipeline počinje pripremom frejmova. Posle toga se procenjuje gusti optički tok i formira body-centered residual flow. Polja se svode na manju rezoluciju i prevode u numeričku reprezentaciju. PCA/SVD zatim izdvaja dominantne motion pravce, a iz njihovih koeficijenata se računaju temporalne osobine.

Na kraju te osobine ulaze u regresioni model. Prednost ovog pristupa je što možemo da nacrtamo flow, da vidimo temporalnu energiju i da približno razumemo šta je ušlo u regresiju. Nedostatak je što ručno izabrane osobine možda ne opisuju dovoljno dobro složenost hoda.

4.3.2 R3D-18 transfer model

Kod transfer grane proces izgleda drugačije. Iz svakog klipa se uzimaju dva deterministička prozora od 16 frejmova, R3D-18 pravi dva 512-dimenziona embeddinga, oni se prosečno agregiraju i L2-normalizuju. PCA sa 64 komponente i whitening fituje se samo na 975 neoznačenih CMU i GaHu klipova. Ove komponente objašnjavaju 96.56% varijanse neoznačenog embedding skupa.

Posle PCA transformacije trenira se mala Ridge glava nad 54 labeled klipa. Backbone ostaje zamrznut. To znači da supervised deo ima relativno mali broj parametara i da se veliki video model ne prilagođava direktno na mali skup.

Proces se može sažeti na sledeće korake:

1. Determinističko vremensko uzorkovanje dva prozora po klipu.
2. Ekstrakcija i cache-iranje zamrznutih R3D-18 embeddinga.
3. Fitovanje PCA/whitening transformacije samo na neoznačenim klipovima.

4. Izbor Ridge regularizacije grupisanom validation ili unutrašnjom CV petljom.
5. Evaluacija kroz MAE, RMSE, R^2 , Spearman i pairwise ranking accuracy.
6. Fitovanje deployment glave na svih 54 označenih klipova tek nakon evaluacije.

4.4 Rezultati

Prvo je korišćen fiksni policy-held-out test. Na istih 12 test klipova upoređeni su R3D-18 transfer model, konstantni train-mean baseline i klasični motion model. Rezultati su dati u Tabeli 4.4.

Tabela 4.4: Poređenje modela na 12 klipova iz dve izdvojene politike

Model	MAE	RMSE	R^2	Spearman	Ranking
R3D-18 transfer	12.35	15.49	0.660	0.877	0.773
Train-mean	22.17	29.48	-0.233	–	–
Klasični motion	35.84	43.64	-1.701	-0.252	0.439

R3D-18 ima za 44.3% manji MAE u odnosu na train-mean baseline i za 65.6% manji MAE u odnosu na klasični motion model. Pozitivan R^2 i Spearman 0.877 pokazuju da model ne vraća samo približno dobar prosek, nego u ovom split-u dosta dobro čuva i redosled klipova, što je možda praktično još zanimljivije ako je cilj da se dve ili više politika međusobno porede. Ipak, test je mali.

Međutim, ovde postoje samo dve test politike. Zbog toga jedan povoljan split nije dovoljan. Da bi se smanjio uticaj izbora baš tih politika, urađena je i nested leave-one-policy-out evaluacija gde svaka od devet politika jednom postaje spoljašnji test.

Tabela 4.5 prikazuje rezultate ovog eksperimenta.

Tabela 4.5: Nested leave-one-policy-out evaluacija R3D-18 modela

Nivo	N	MAE	RMSE	R^2	Spearman	Ranking
Klip	54	11.23	13.64	0.638	0.782	0.790
Policy prosek	9	5.84	6.99	0.830	0.983	0.972
Leave-one mean	9	15.59	19.07	-0.266	–	–

Na nivou klipa MAE je 11.23. Kada se šest scenarija agregira u jedan skor politike, MAE pada na 5.84, a Spearman raste na 0.983. Ovo ima smisla jer pojedinačni scenario može da bude neuobičajeno lak ili težak, dok prosek više scenarija bolje predstavlja opšte ponašanje politike.

4.5 Statistička pozadina rezultata

MAE od 5.84 na devet politika zvuči dosta bolje od 11.23 na klipovima, ali ta dva broja nisu direktno ista vrsta problema. Prvi ima $N = 9$ i predstavlja agregirane politike, a drugi $N = 54$ i predstavlja pojedinačne klipove. Zbog toga se u radu oba rezultata prikazuju odvojeno.

Takođe, šest scenarija jedne politike nisu šest nezavisnih subjekata. Oni imaju isti kontroler i zbog toga su međusobno korelisani. Ovo je razlog za grupisanu podelu po politici. Random podela po klipu bi verovatno proizvela optimističniji rezultat, ali ne bi proveravala glavno pitanje rada.

Tokom prvog izvlačenja 1154 video embeddinga na NVIDIA RTX 2060 GPU-u bilo je potrebno oko 16 minuta. Kada je cache popunjen, ponavljanje traje oko 25 sekundi. Ovaj detalj nije mera tačnosti modela, ali je praktično bitan jer pokazuje da se skupi backbone korak može uraditi jednom, a kasnije se eksperimenti sa Ridge modelom izvode dosta brže.

5 PRIMENA MODELA NA WALKER POLITIKE

Rezultat jednog klipa je koristan, ali je praktično zanimljivije oceniti celu walker politiku. Politika se ne posmatra samo u jednom forward hodu, jer može da bude dobra pri jednoj brzini, a loša pri skretanju ili lateralnom kretanju. Zbog toga deployment komanda koristi više scenarija.


5.1 Vizuelni prikazi

Klasična grana daje optički tok i temporalnu heatmap-u. Ovi prikazi nisu dokaz da je neki frejm izazvao određenu R3D-18 predikciju, ali su korisni za proveru samog videa i kretanja. Na slici 5.1 prikazan je optical flow za jedan audit klip.



Slika 5.1: Vizuelizacija optičkog toka za jedan MuJoCo klip.

Na slici 5.2 prikazana je temporalna energija kretanja za isti primer. Ovde se mogu videti delovi sekvence gde postoji veća promena u motion signalu.



Slika 5.2: Temporalna energija kretanja za jedan MuJoCo klip.


Ovakav prikaz može da pokaže nagli prekid, globalni drift ili vrlo neobičan motion

obrazac. Ne treba ga predstavljati kao Grad-CAM ili kao frame-level objašnjenje dubokog modela, jer to nije.

5.2 Policy-level ocenjivanje

Za novu politiku model se učitava jednom i zatim ocenjuje side-view snimke scenarija `forward`, `forward_slow`, `forward_fast`, `turn`, `lateral` i `diagonal`. Iz tih šest predikcija računaju se prosek, standardna devijacija, minimum, maksimum i rezultat po scenariju.

Nested policy rezultati su prikazani na slici 5.3. Levo su held-out proseci za svih devet politika, dok se desno poredi policy MAE R3D-18 modela i leave-one-policy mean baseline-a.



Slika 5.3: Nested held-out rezultati po politici i poređenje policy-level MAE.

Kao funkcionalni sanity check, poznata politika P01 je ocenjena preko svih šest scenarija. Pošto je P01 deo training kohorte, ovaj primer nije evaluacioni dokaz i ne koristi se za tvrdnju o generalizaciji. Tabela 5.1 prikazuje dobijene vrednosti.

Tabela 5.1: Primer policy-level izlaza za P01

	diag.	forward	fast	slow	lateral	turn	prosek
Skor	80.33	90.80	82.35	93.64	73.05	74.46	82.44

Standardna devijacija je 7.66. Svih 6/6 snimaka je prošlo camera i OOD proveru, pa je policy skor označen validnim. Razlika između scenarija nije mala, što je još jedan razlog da se politika ne ocenjuje samo jednim klipom.

5.3 Promena domena i OOD provera

Model je treniran i evaluiran prvenstveno na side-view walking domenu. Ako se pošalje frontalni video realne osobe, nije razumno očekivati da ista reprezentacija automatski ostane pouzdana. Problem detekcije ulaza van trening distribucije predstavlja poseban problem u mašinskom učenju [19]. Zato postoji OOD provera koja meri udaljenost u reprezentacionom prostoru.

Prag udaljenosti trening domena je 1.661, dok frontalni DisabledGait klipovi imaju medijanu 2.307 i 95. percentil 2.559. To pokazuje da se ovaj frontalni realni skup nalazi dalje od domena na kome je scoring sistem zamišljen. Praktična posledica je da takav ulaz dobija upozorenje. To nije dokaz da model zna da ocenjuje realan ljudski hod, nego upravo suprotno, signal da mu takav ulaz ne treba verovati.

6 OGRANIČENJA I BUDUĆI RAD

Najvažnije ograničenje je target. Ukupni skor dolazi iz simulatora, pa model uči da aproksimira simulator evaluation funkciju i samim tim sve što je dobro ili loše u definiciji te funkcije ulazi posredno i u naš zadatak; ako je neki reward proxy loše postavljen, vizuelni model to neće magično ispraviti samo zato što gleda video. Visok predviđeni skor zato ne znači automatski prirodan ili biomehanički ispravan hod.

Drugo ograničenje je što RGB video nema direktnu informaciju o silama, kontaktima i unutrašnjim stanjima kontrolera. Neke nepravilnosti su veoma vidljive, na primer pad ili veliko klizanje. Druge mogu da budu dinamički problem, a da u videu izgledaju skoro normalno. To predstavlja fundamentalno ograničenje ulaznog senzora.

Treći problem je veličina skupa. Devet politika je malo. Postoji 54 klipa, ali broj stvarno nezavisnih kontrolera je devet. Nested evaluacija je zbog toga bitnija od običnog random video split-a, ali ni ona ne može da napravi više nezavisnih podataka nego što ih stvarno postoji.

Promena kamere je dodatni problem. Side-view je veoma zgodan za hod jer se pokret nogu jasno vidi, dok frontalni video ima sasvim drugačiju geometriju kretanja. DisabledGait eksperiment pokazuje da takav domain shift može da se detektuje, ali ne pokazuje da je rešen.

Budući rad bi trebalo prvo da proširi simulator dataset, a tek zatim da pravi složeniji model. Najvažniji koraci su:

- testiranje zamrznutog v1 protokola na većem broju novih walker politika;
- dodavanje više kamera i posebno odvojena evaluacija po kameri;
- prikupljanje realnih side-view snimaka sa nezavisnim ljudskim ocenjivanjem;
- odvajanje subjekata i lokacija između treninga i finalnog testa;
- kontrolisano fine-tune-ovanje poslednjeg R3D bloka tek sa većim labeled skupom;
- bolja kalibracija uncertainty i unapred definisan kriterijum odbijanja OOD ulaza.

OU-ISIR Treadmill Dataset je evidentiran kao mogući dodatni izvor podataka, ali pristup zahteva institucionalni release agreement i zbog toga nije uključen u trenutni eksperiment [10].

7 ZAKLJUČAK

U ovom radu razvijen je sistem za vizuelnu procenu kvaliteta hoda MuJoCo humano-idnih politika. Za razliku od direktne evaluacije simulatora, model tokom inferencije dobija samo spoljašnji RGB video. Simulator se koristi za labelu, ali ne i kao dodatni ulaz modela.

Razmatrana su dva pristupa. Klasični model koristi optički tok, poravnanje, PCA/SVD motion reprezentaciju i regresiju. Ovaj pristup se dobro povezuje sa teorijom iz Szeliski knjige i daje korisne dijagnostičke prikaze, ali je na trenutnom skupu imao slabiju numeričku tačnost. R3D-18 transfer model koristi prethodno naučenu spatiotemporalnu reprezentaciju i pokazao je značajno bolje rezultate.

Na fiksnom policy-held-out testu R3D-18 postiže MAE 12.35, dok nested leave-one-policy-out evaluacija daje clip-level MAE 11.23. Kada se šest scenarija objedini na nivo politike, MAE je 5.84, $R^2 = 0.830$ i Spearman korelacija 0.983. Iz ovoga zaključujemo da video zaista sadrži signal dovoljan za korisno rangiranje i približnu procenu definisanog simulacionog skora.

Međutim, rezultat ne treba proširivati više nego što podaci dozvoljavaju. Model nije klinički gait assessor, nije testiran kao sistem za dijagnozu ljudi i nije dokazano da će raditi na proizvoljnoj kameri. Njegova trenutna vrednost je u evaluaciji simuliranih walker politika i kao osnova za dalje eksperimente. Sa većim brojem politika, boljim targetom i nezavisnom ljudskom procenom, ovaj pristup bi mogao da postane dosta korisniji.

LITERATURA

1. Richard Szeliski, *Computer Vision: Algorithms and Applications*, draft version, September 3, 2010.
2. Gunnar Farneback, *Two-Frame Motion Estimation Based on Polynomial Expansion*, 2003.
3. PECoP, *Parameter Efficient Continual Pretraining for Action Quality Assessment*, WACV 2024.
4. Du Tran, Heng Wang, Lorenzo Torresani, Jamie Ray, Yann LeCun i Manohar Paluri, *A Closer Look at Spatiotemporal Convolutions for Action Recognition*, CVPR 2018.
5. Torchvision R3D-18 video model sa Kinetics-400 V1 pretreniranim težinama, <https://docs.pytorch.org/vision/stable/models.html>.
6. CARE-PD repository, korišćen kao konceptualna referenca za procenu hoda i organizaciju AQA eksperimenta.
7. Projekat mujoco-bipedal-joystick-walker, korišćen kao izvor renderovanih sekvenci i simulator label signala.
8. Resty Wulanningrum, Anik Nur Handayani i Heru Wahyu Herwanto, *DisabledGait: Gait Dataset of Normal People and People with Disabilities*, Mendeley Data, version 2, 2024, DOI: 10.17632/v6hy35ydch.2.
9. Edward Guillen Pinto, Leonardo Ramirez Lopez i Carlos Ramos Linares, *GaHu-Video: Parametrization System for Human Gait Recognition*, Mendeley Data, version 1, 2020, DOI: 10.17632/gprg4s73v4.1.
10. OU-ISIR Gait Database, Treadmill Dataset, Osaka University. Skup je evidentiran samo kao kandidat za budući rad jer pristup zahteva potpisan institucionalni release agreement.
11. Bruce D. Lucas i Takeo Kanade, *An Iterative Image Registration Technique with an Application to Stereo Vision*, Proceedings of the 7th International Joint Conference on Artificial Intelligence (IJCAI), vol. 2, str. 674–679, 1981.

12. Berthold K. P. Horn i Brian G. Schunck, *Determining Optical Flow*, Artificial Intelligence, vol. 17, br. 1–3, str. 185–203, 1981, DOI: 10.1016/0004-3702(81)90024-2.
13. Michael J. Black, Yaser Yacoob, Allan D. Jepson i David J. Fleet, *Learning Parameterized Models of Image Motion*, Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), str. 561–567, 1997, DOI: 10.1109/CVPR.1997.609381.
14. Ian T. Jolliffe i Jorge Cadima, *Principal Component Analysis: A Review and Recent Developments*, Philosophical Transactions of the Royal Society A, vol. 374, br. 2065, 20150202, 2016, DOI: 10.1098/rsta.2015.0202.
15. Arthur E. Hoerl i Robert W. Kennard, *Ridge Regression: Biased Estimation for Nonorthogonal Problems*, Technometrics, vol. 12, br. 1, str. 55–67, 1970, DOI: 10.1080/00401706.1970.10488634.
16. Sinno Jialin Pan i Qiang Yang, *A Survey on Transfer Learning*, IEEE Transactions on Knowledge and Data Engineering, vol. 22, br. 10, str. 1345–1359, 2010, DOI: 10.1109/TKDE.2009.191.
17. Joao Carreira i Andrew Zisserman, *Quo Vadis, Action Recognition? A New Model and the Kinetics Dataset*, Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), str. 6299–6308, 2017.
18. Paritosh Parmar i Brendan Tran Morris, *Learning to Score Olympic Events*, Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), 2017.
19. Dan Hendrycks i Kevin Gimpel, *A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks*, International Conference on Learning Representations (ICLR), 2017.
20. Jiang Liu, Huasheng Wang, Katarzyna Stawarz, Shiyin Li, Yao Fu i Hantao Liu, *Vision-Based Human Action Quality Assessment: A Systematic Review*, Expert Systems with Applications, vol. 263, 125642, 2025, DOI: 10.1016/j.eswa.2024.125642.